Mourchid Jibaya مرشد جباية — assistant fiscal IA 24h/24 fondé sur les textes officiels

Défi principal : T9 — Chatbot / agent virtuel IA 24h/24 (axe 2). **Défi complémentaire :** T4 — Facilitation pour les contribuables.
Équipe : Sameh Gassouma (conseillère fiscale depuis 2007) · Cyrine Gassouma.

Travaux préparatoires (art. 6.1) : recherche documentaire sur les sources officielles et maquette exploratoire réalisées avant le hackathon. Le code déposé a été entièrement réécrit pendant le hackathon ; l'historique Git horodaté du dépôt en fait foi.

1. Défi choisi et problème

Les contribuables — TPE, professions libérales, personnes physiques — doivent suivre des textes dispersés (codes, lois de finances, notes communes, calendrier fiscal) et plusieurs plateformes. Les mêmes questions saturent les guichets ; erreurs et retards génèrent pénalités et encaissements tardifs. La loi de finances 2026 (art. 53) étend la facture électronique à toutes les prestations de services. Mourchid Jibaya répond à toute heure, en arabe, darija, français et anglais, uniquement à partir des textes officiels, et cite chaque référence (T9). Il donne à chaque contribuable ses échéances et vérifie sa TVA avant dépôt (T4).

2. Approche technique

- **Compréhension :** détection de la langue, normalisation de l'arabe (alef, hamza, diacritiques), racinisation légère (préfixes et suffixes arabes), correction des fautes de frappe par distance d'édition, lexique de concepts reliant l'arabe, la darija, le français et l'anglais (ex. « الأداء على القيمة المضافة » = TVA = VAT).
- **Recherche :** index BM25 pondéré par champ (titre, questions types, mots-clés, réponse) sur les fiches officielles.
- **Seuil de confiance et garde-fous :** une réponse n'est donnée que si le score, la couverture de la question et le nombre de termes retrouvés suffisent ; sinon « je ne sais pas », fiches proches et ticket pour un agent. Les demandes d'aide à la fraude sont refusées.
- **Génération contrainte (optionnelle) :** un modèle de langage peut reformuler la réponse à partir de la seule fiche retrouvée ; « NO_SOURCE » sinon, et retour à la fiche officielle.
- **Validation humaine et apprentissage :** chaque fiche porte sa référence, son lien, son état et sa date de vérification ; l'expert valide les fiches dans une page d'administration et répond aux questions restées sans réponse, qui deviennent de nouvelles fiches aussitôt utilisées.
- **Échéances (T4) :** calendrier par profil avec report automatique des dimanches et jours fériés ; vérification de la TVA d'une déclaration mensuelle et du délai.

3. Données et modèles utilisés

- **Corpus :** 34 fiches tirées de textes officiels publics — loi de finances 2026, Code IRPP/IS, Code de la TVA, CDPF, Code de la fiscalité locale, notes communes DGI (02/2026, 04/2026, 03/2025, 07/2025, 08/2023), loi n° 2018-52 (RNE), décret n° 2019-54 ; portails jibaya.tn, RNE et TunTrust.
- **Données simulées :** montants saisis par l'usager dans « Vérifier ma déclaration ». Aucune donnée personnelle ou confidentielle ; aucun accès aux systèmes de l'administration.
- **Modèles et bibliothèques tiers :** aucun modèle entraîné par l'équipe. Modèle de langage optionnel, désactivé par défaut : API Claude (Anthropic) ou modèle local via Ollama. Python 3, bibliothèque standard uniquement ; HTML/CSS/JavaScript sans framework. Développement assisté par IA : Claude (Anthropic).

4. Résultats obtenus

Mesure	Résultat
Jeu indépendant : 25 formulations nouvelles (FR, AR/darija, EN)	24/25 bonnes fiches, source citée
Questions hors sujet	4/4 transférées à un agent, aucune invention
Non-régression : 53 questions de référence	53/53
Tests automatisés (moteur, échéances, garde-fous, vérification)	14/14 réussis
Temps de réponse moyen (sans modèle de langage)	< 1 ms par question
Base de fiches	34 : 20 « source officielle », 13 « à confirmer », 1 interne

5. Limites identifiées

- 13 fiches restent à relire sur le texte officiel ; l'ensemble doit être validé par la DGI.
- Couverture limitée aux sujets des fiches ; les formulations éloignées sont transférées à un agent (1 erreur sur 25 au test indépendant).
- Dates des fêtes religieuses estimées ; montant exact des pénalités de retard non calculé.
- Vérification limitée à la TVA mensuelle, sur montants saisis ; aucune connexion aux plateformes de l'administration.

6. Recommandations pour une mise en production

- **Validation :** cellule DGI chargée de valider chaque fiche et d'intégrer chaque nouveau texte.

- **Souveraineté et conformité :** hébergement en Tunisie, modèle de langage local, journalisation, conformité à la loi organique n° 2004-63 et déclaration à l'INPDP.
- **Pilote de 3 mois :** un centre des impôts et un groupe témoin ; indicateurs : dépôts dans les délais, passages au guichet, déclarations corrigées, pénalités, questions résolues sans agent.
- **Intégration :** connexion aux API Jibayti et El Fatoora (TTN) avec l'autorisation des administrations ; canaux WhatsApp et voix ; extension au RNE et à la douane.